1. Estadística. Concepto

Podemos definir la estadística como el conjunto de métodos científicos ligados con la toma, organización, recopilación, presentación y análisis de datos, tanto para la deducción de conclusiones como para tomar decisiones razonables de acuerdo con tales análisis. Una definición más funcional sería "el arte de tomar decisiones en presencia de incertidumbre".

Dentro de la estadística podemos diferenciar dos tipos: la **estadística descriptiva** y la **inferencial**. La estadística descriptiva se limita a describir y analizar un conjunto de datos, limitándose a los mismos, mientras que la estadística inferencial (o inductiva) intenta obtener conclusiones sobre una población a partir del análisis de los datos extraídos de un subconjunto de ella (muestra). La inferencia estadística es el objetivo principal de la estadística, ya que es la que nos permite cuantificar nuestra incertidumbre y tomar decisiones, cuando la probabilidad de error es mínima. Dentro de la inferencia estadística, podemos diferenciar a su vez dos tipos de estrategias: la estimación de intervalos de confianza de nuestras estimaciones y el contraste de hipótesis en el que confrontamos dos o más alternativas, cuantificando la probabilidad de que las diferencias entre ellas se deban al azar.

Veamos un ejemplo para ilustrar las distintas funciones de la estadística: imaginemos que en una muestra de 63 niños con dolor de cabeza recurrente, se prueba en episodios sucesivos dos analgésicos distintos (tratamiento A y B). De ellos, **31** manifestaron preferencia por el **tratamiento A**, **15** por el **tratamiento B** y **17 no mostraron preferencia** entre ellos. La *estadística descriptiva* nos permite estimar que un **49.2%** prefirieron el tratamiento A, **un 23.8%** el tratamiento B, con una diferencia entre ambos del **25.4%** a favor del tratamiento A.

La *inferencia estadística*, mediante estimación de intervalos, nos permite avanzar hasta estimar que con un **95**% de confianza (5% de error) la diferencia observada se situaría en un intervalo entre el **3.6**% y **47.2**% a favor del tratamiento A.

Por último, el contraste de hipótesis nos permite calcular (test de McNemar) que la probabilidad de que las diferencias encontradas sea originada al azar es del **0.018 (1.8%)**, por lo que asumimos que el tratamiento A parece mejor que el B.

Los elementos de análisis de la estadística son las *variables*, que son características medidas en los sujetos de estudio, que pueden adoptar una serie de valores posibles, pero cuyo valor concreto en cada sujeto u observación es *a priori* desconocido. En el ejemplo anterior, las variables son el tipo de analgésico tomado (A y B) y la respuesta al mismo.

1.1 Variables

Una *variable* es toda aquella característica que puede medirse en un estudio, en donde su medición se realiza con valores numéricos (*variables cuantitativas*: *edad* o *peso*) o en categorías (*variables cualitativas* o *categóricas*).

Se denomina variable porque, aunque se pueden prever los valores posibles (**espacio muestral**), el valor observado en un momento dado en un individuo, grupo, comunidad o población es *cambiante*. Por ejemplo, se puede prever que los valores posibles del sexo de un nuevo recién nacido pueden ser *masculino* o *femenino*, pero hasta que no se observa al nuevo recién nacido no se puede asegurar cuál de ellos es. En este ejemplo la unidad de observación es el *recién nacido*, y el *conjunto de recién nacidos examinados* es la muestra de estudio.

Aunque la mayoría de las variables de uso frecuente pueden ser de fácil comprensión, existen otras que no lo son y, por lo tanto, requerirán una definición operativa. Dicha definición incluirá el rango de valores posibles y la definición de cada uno de ellos. Por ejemplo: la evolución de una enfermedad.

Podemos definir como valores posibles: *curación* (desaparición de síntomas), *mejoría* (disminución de la intensidad de los síntomas), *persistencia* o *empeoramiento* (persistencia o empeoramiento de síntomas).

Las variables se diferencian en función de diversas características (Tabla 1): su papel en la pregunta de investigación, el número de posibles valores y su escala de medición. Es importante conocer las características de las variables ya que van a condicionar su recogida y análisis. Cuando presentemos los distintos test estadísticos comprenderemos la trascendencia del tipo de variables en la elección de los mismos.

DefiniciónTipoSegún su papel en la pregunta de investigaciónDependiente (respuesta)Independiente (explicativa o exposición)Según el número de valores posiblesContinuasDiscretasNominal (dicotómica, politómicas)OrdinalDe intervalos (continuas o de escala)De razones (continuas o de escala)

Tabla 1. Tipos de variables.

1.1.1 Papel en la pregunta de investigación

Podemos diferenciar las variables en función del papel que desempeñen en nuestra pregunta de investigación. Si estudiamos la asociación entre dos variables las denominaremos como **dependiente** e **independiente** respectivamente. La que recibe el nombre de *dependiente* (variable resultado o de efecto) es aquella que está condicionada por la otra variable, que denominamos *independiente* (variable explicativa o de exposición).

Por ejemplo, si queremos estudiar la *prevalencia de diabetes* en una muestra de población y conocer las variaciones según la *edad* y el *sexo* de sus componentes, la *presencia de diabetes* sería la *variable dependiente* y la *edad* y el *sexo* las *variables independientes*. Por el contrario, si estudiamos la *influencia de la diabetes* sobre los *niveles de presión arterial*, esta sería la *variable dependiente* y la *diabetes* se consideraría *variable independiente*.

1.1.2 Número de valores posibles en su espacio muestral

Son variables **continuas** las que pueden adoptar un número teóricamente *infinito* de valores a lo largo de un espacio muestral continuo (ejemplo: *talla*, *peso*). Son **discretas** cuando solo son posibles un número *finito* de valores (ejemplo: *número de hijos* de una pareja; esta variable no puede tener fracciones). A la hora de identificar las variables continuas debemos tener en cuenta que, aunque los valores teóricamente posibles sean infinitos, muchas muestras contienen valores finitos, bien por tener escasas observaciones o por falta de precisión en la medición (ejemplo: *medición sin decimales*).

Las variables **discretas** pueden medirse en cualquier **escala**, aunque habitualmente se medirán en escalas *nominales* u *ordinales*, mientras que las variables **continuas** solo pueden medirse en **escalas** de *intervalos* y de *razones*.

1.2 Escalas de medición de variables

Uno de los elementos fundamentales de la definición de una variable es el tipo de escala que se utiliza para su medición. En función de la escala elegida se decide su codificación, tratamiento computacional y estadístico.

Hay cuatro tipos de escalas de medición, que ordenadas en orden creciente de potencia, según la proporción de información que contienen, son:

- Nominal.
- Ordinal.
- De intervalos.
- De razones o proporción.

1.2.1 Escala nominal

Consta de dos o más categorías **mutuamente excluyentes**. Si solo hay dos, se llama escala nominal **dicotómica**. A cada categoría se le suele asignar un número de código sin un significado cuantitativo, lo que facilita su implementación en bases de datos. En cualquier situación, si se usa una codificación propia, debe tenerse claro lo que significa cada código para cada variable.

Veamos algunos ejemplos:

- Sexo: 1) masculino; 2) femenino.
- Fumar: 0) no; 1) sí.
- Estado civil: 1, casado; 2, soltero; 3, viudo; 4, divorciado,
- Ingreso médico: 1, urgencias; 2, consultas; 3, otro hospital.

Dependiendo de la herramienta que se utilizará para el análisis, se prefiere codificar las variables nominales dicotómicas de forma que la presencia de enfermedad o del factor de exposición se suele codificar como uno (1), mientras que la ausencia de enfermedad o de exposición a algún factor como cero (0) o dos (2).

Por ejemplo, el antecedente de hábito de fumar puede codificarse como 1 y 0 (1: fumador; 0: no fumador) o como 1 y 2 (1: fumador; 2: no fumador). Aunque matemáticamente la presencia/ausencia de una característica se corresponde con la codificación 1 - 0, es frecuente usar la codificación 1 - 2, para evitar que variables vacías sean asignadas al 0 por error.

1.2.2 Escala ordinal

Las variables ordinales tienen una cualidad adicional, respecto a la escala nominal, de que **sus categorías están ordenadas por rango**; cada *clase* posee una misma relación posicional con la siguiente; es decir, la escala muestra situaciones escalonadas. Si se usan números, su único significado está en indicar la posición de las distintas categorías en la serie; sin embargo, no asumen que la distancia del primer escalón al segundo sea la misma que la del segundo al tercero.

Veamos algunos ejemplos:

- Clase social:
 - o 1) baja,
 - o 2) media,
 - o 3) alta.
- Grados de reflujo vesicoureteral:
 - o grados 1, 2, 3, 4.
- De acuerdo con una afirmación:
 - o 0) completo desacuerdo,
 - o 1) acuerdo parcial,
 - o 2) acuerdo total.
- Fumar:
 - o 0) no fumador,
 - o 1) fumador leve, <10/día;
 - o 2) fumador moderado, 10-20/día,
 - o 3) gran fumador, >20/día).

Existen escalas que serán una **mezcla de nominal y ordinal**, porque solo algunas categorías estarán ordenadas por rango; esto ocurre en las escalas en las que un valor representa a una categoría que no puede clasificarse (ejemplo: cuando no sabe no contesta o un resultado indeterminado).

1.2.3 Escalas de intervalos

Las escalas de intervalos poseen la característica adicional de que los **intervalos entre sus clases son iguales**. Las diferencias iguales entre cualquier par de números de la escala indican diferencias también iguales en el atributo sometido a medición.

Veamos un ejemplo: la diferencia de temperatura entre una habitación a 22 grados centígrados y otra a 26 es la misma, que la existente entre dos habitaciones con temperaturas de 33 y 37 grados centígrados, respectivamente.

Sin embargo, la **razón** entre los números de la escala no es necesariamente es la misma que la existente entre las cantidades del atributo. Por ejemplo: una habitación a 20 grados no está al doble de caliente que otra a 10 grados. Esto se debe a que el cero de la escala no expresa el valor *nulo* o *que el cero de la escala no expresa el valor nulo* o *que el cero de la escala no expresa el valor nulo* o *que el cero de la escala no expresa el valor nulo* o *que el cero de la escala no expresa el valor nulo* o *que el cero de la escala no expresa el valor nulo* o *que el cero de la escala no expresa el valor nulo* o *que el cero de la escala no expresa el valor nulo* o *que el cero de la escala no expresa el valor nulo* o *que el cero de la escala no expresa el valor nulo* o *que el cero de la escala no expresa el valor nulo* o *que el cero de la escala no expresa el valor nulo* o *que el cero de la escala no expresa el valor nulo* o *que el cero de la escala no expresa el valor nulo* o *que el cero de la escala no expresa el valor nulo* o *que el cero de la escala no expresa el valor nulo* o *que el cero de la escala no expresa el valor nulo* o *que el cero de la escala no expresa el valor nulo* o *que el cero de la escala no expresa el valor nulo* o *que el cero de la escala no expresa el valor nulo* o *que el cero de la escala nulo expresa el valor nulo* o *que el cero de la escala nulo el cero d*

1.2.4 Escalas de razones

Su característica adicional es que el **cero sí indica una ausencia de atributo**. En consecuencia, la razón entre dos números de la escala es igual a la existente entre las cantidades del atributo medido. Ejemplos:

- Peso: medido en kilogramos.
- Concentración de glucosa en una muestra: medida en mg/dl.
- Tasa de mortalidad: muertes por 1,000 personas en riesgo.
- Ingresos: medidos en dólares.

Las escalas de intervalos y razones se llaman también *métricas* o *dimensionales*. Las variables continuas van a medirse con escalas de razones o intervalos, por lo que es habitual que nos refiramos a ellas englobándolas como **escalas continuas**, ya que comparten estrategias de análisis, como la

elección del test estadístico. Algunas herramientas de software estadístico como SPSS, las denominan simplemente "**escalas**".

Cuando en la definición e implementación de una variable continua (escala de razones o intervalos) no podemos tomar valores a partir de un límite (por ejemplo: cargas virales superiores a 100,000), si optamos por mantener esas observaciones en el análisis, la variable se comporta en ese rango como una variable ordinal. En la Tabla 2 se presenta un resumen de las características de las diferentes escalas de medida.

Tabla 2. Características de las diferentes escalas de medida de variables.

| Tipo Escala | Operatividad | Requisito |
|--------------------|---------------------------|--------------------------------------|
| Nominal | Igualdad/desigualdad | Mutuamente excluyentes Exhaustividad |
| Ordinal | Jerarquía mayor/menor | Escalonamiento (orden creciente) |
| Intervalos | Comparación de intervalos | Unidad contante |
| Razón o Proporción | Comparación continua | Cero absoluto |

1.3 Elección de las escalas

La selección de una escala estará determinada por la definición operativa de la variable que hayamos realizado y por los métodos disponibles para medirla. Para algunas variables solo existirá un tipo de escala elegible, mientras que para la mayoría tendremos varias alternativas.

En general, siempre que sea posible, interesa utilizar en la selección y uso de datos la escala más precisa, aunque no sea la que posteriormente se utilice en el tratamiento estadístico. Esto nos permitirá conocer sobre la verdadera distribución de nuestros datos. Por ejemplo, siempre será preferible recoger el número de cigarros que fuma una persona al día que el **dato categorizado** como <10, 10-20, >20; la primera estrategia facilitará la búsqueda durante el análisis de puntos de corte distintos a los empleados *a priori*.

Cuando se categorizan algunas variables, como la edad o los ingresos económicos, pasan de ser *variables continuas (de intervalos o de razones)* a *variables ordinales o nominales*, según los puntos de corte elegidos.

Si una variable continua se limita en uno de sus extremos con una categoría abierta (por ejemplo, carga viral mayor de 100,000 [carga viral > 100,000]), forzamos que tenga que ser considerada como ordinal.

Las categorías de las variables deben estar claras y operativamente definidas, la escala debe ser exhaustiva (incluir todas las posibilidades) y las clases mutuamente excluyentes (cada observación solo puede ser asignada a una opción). A menudo tendremos que recurrir a categorías complementarias que cubran todo el espectro como "otras", "no aplicable" o "desconocido", o establecer un orden de prioridades en caso de opciones intermedias.

Las escalas utilizadas para medir variables combinadas se llaman **escalas compuestas**, pueden basarse en combinaciones de categorías (por ejemplo: combinación de varios criterios diagnósticos simultáneos para asignar el estado de un tumor), en el uso de fórmulas (por ejemplo: índice de masa

corporal = peso / talla) o de puntuaciones compuestas, obtenidas tras la suma de las asignadas a los distintos elementos implicados (por ejemplo, puntuación del test de Apgar).

Para poder diferenciar las escalas de medidas de una variable se recomienda hacer dos preguntas encadenadas:

- ¿Los valores posibles de la variable son teóricamente infinitos? Si los valores son teóricamente infinitos, la escala de medida será continua, ya sea de intervalos, o bien de razones. Aunque la característica operativa de estas escalas es que la unidad de medida es constante, en la práctica la mayoría de las variables continuas cumplen este criterio. No tiene mucho interés diferenciar si la escala es de intervalos o de razones (existe el 0 absoluto), ya que ambas escalas comparten características de análisis. Si la respuesta es negativa pasaríamos a la siguiente pregunta.
- 2. ¿Están los posibles valores ordenados entre sí? Si los posibles valores están ordenados entre sí la escala es ordinal. Si la respuesta es negativa la escala es nominal.